

Clasificación de conductas de manejo

Resumen

Los accidentes viales, especialmente choques fatales, son una problemática ocasionada en su mayoría por comportamientos irresponsables de los conductores. Así pues, se busca obtener un modelo que, a partir de estos comportamientos, pueda identificar a los conductores agresivos que podrían causar estos accidentes.

Los datos de entrenamiento provistos, clasifican los conductores en tres clases: lento, normal y agresivo. Entonces, se inicia por elaborar modelos que ubiquen los datos en alguna de esas tres clases; luego se pasa a modelos de dos salidas para dividir a los conductores en “agresivos” y “no agresivos”; finalmente, manteniendo las clases “agresivo” y “no agresivo”, se entrenan modelos a partir de la desviación estándar de los datos por intervalos de tiempo.

Palabras clave

Modelos de aprendizaje

Tipo de manejo

Clasificación

Introducción

En los accidentes de tráfico, las y los conductores agresivos han sido un factor importante. De acuerdo con la AAA Foundation for Traffic Safety (Aggressive Driving: Research Update, 2009), 106,727 choques fatales (55.7% del total) durante un periodo de 4 años involucraron conductores que cometieron una o más acciones agresivas al manejar. Para estimar la forma de conducir de una persona se pueden entrenar distintos modelos. Así pues, ¿cómo podemos predecir comportamientos peligrosos?

La inteligencia artificial puede ser aplicada para encontrar una solución al problema: los modelos de clasificación (que son un tipo de inteligencia artificial) nos permiten determinar el conjunto o clase al que pertenecen ciertos datos. Con esto, se decide entrenar distintos modelos con la finalidad de encontrar alguno que clasifique confiablemente a las personas con tendencia agresiva.

En la primera sección del documento se habla del preprocesamiento que necesitaron los datos para ser usados en clasificadores. En la segunda sección se explica la implementación de distintos modelos para estimar tres clases. En la tercera sección se detalla el desarrollo de modelos para clasificar específicamente a los conductores agresivos y no agresivos (dos clases). En la cuarta sección se describe el proceso usado

para medir los comportamientos agresivos (a partir de la desviación estándar) y con esto estimar la clase. Por último se observan los resultados y se puntualizan ciertos aspectos para mejorar la precisión de los modelos.

Metodología

Preprocesamiento y Análisis de Datos

Primero es necesario conocer la estructura de los datos. La única variable categórica del dataset es la clase del conductor, para poder facilitar el análisis y comparación de los datos creamos una nueva columna que expresa las clases numéricamente:

1. Lento
2. Normal
3. Agresivo

Antes de poder realizar cualquier tipo de procesamiento de datos, es necesario revisar la existencia de datos vacíos en el dataset. Al no encontrar datos vacíos, se omite el paso de imputar datos.

Comenzamos formalmente con el análisis básico de las variables: coeficientes de correlación, gráficas de dispersión, histogramas y cálculo de cuartiles. Observando las gráficas, se aprecia que existe un empalme de clases con los datos, lo que dificulta su clasificación. Además hay una notable cantidad de datos atípicos; por lo que se trató de depurar los datos (eliminar los atípicos) buscando que fuera más sencillo distinguir las clases, pero esto vuelve el dataset fundamentalmente inútil dado que la muestra deja de ser representativa de la población.

Consideraciones generales

Escalaciones: para entrenar algunos modelos decidimos usar distintos escalamientos, estándar, robusto y mínimos-máximos. El primero estandariza las variables eliminando la media y escalando a la varianza unitaria; el robusto, elimina la mediana y escala los datos de acuerdo con el rango de cuartiles (por defecto IQR -rango intercuartílico-); y el método de mínimos-máximos escala de tal manera que los datos estén en el rango decidido para el conjunto de entrenamiento, por ejemplo, entre cero y uno.

Correlación: la correlación de cada característica con la clase es uno de los principales indicadores usados para seleccionar las variables estimadoras.

Métricas de éxito: para evaluar la confiabilidad de los modelos decidimos usar dos métricas, porcentaje de precisión y matriz de confusión.

Modelos para clasificar en 3 clases

Se decidió emplear dos modelos de clasificación: regresión logística y kNN, cada uno con implementaciones distintas de escalamiento, con el fin de estimar las clases normal, lento y agresivo. Así

mismo, dada la pequeña correlación que tienen la aceleración en z y el giroscopio en x con la clase del conductor decidimos probar modelos sin estas variables.

Inicialmente se entrenaron los modelos de regresión logística y kNN sin escalar los datos, posteriormente se escalaron de tres formas distintas: estandarización, escalamiento robusto y método de mínimos-máximos. En kNN se usó el método euclidiano para calcular distancias.

Modelo de 2 clases e intervalos

Como se mencionó anteriormente, más del 55% de los accidentes de tráfico fatales se cometieron por acciones agresivas, por ello es importante estimar si una persona conduce o no de forma agresiva (variable aleatoria binaria). Con este objetivo en mente, se entrenaron distintos modelos donde las clases lento y normal se agruparon y convirtieron en no-agresivo, usando variables aleatorias binarias, y por ende más sencillas computacionalmente de clasificar.

Modelo de 2 clases

En el modelo de 2 clases se usaron 3 modelos distintos: regresión logística, kNN y random forest, esto para poder comparar junto con el de 3 clases y tener un modelo nuevo el cual se acopla a nuestro output binario esperado. Todos los modelos son sin escalamientos.


Se tomó en cuenta la clase normal y la agresiva al momento de entrenar los distintos modelos. En cambio al probar se toma la clase lento como normal.

Modelo de intervalos

Cabe notar que los datos se realizaron con un solo automóvil haciendo registros de un instante a otro, pero este comportamiento no refleja la realidad: las personas no conducen agresivamente en un milisegundo solamente. Entonces, se consideró agrupar los datos de la muestra en intervalos de tiempo para tratar de corroborar que el conductor realmente es agresivo.

Los conductores clasificados como agresivos tienen más comportamientos erráticos, lo cual se muestra en los datos registrados.

Al ser agresivo, se tienen más valores atípicos. Si trazamos una línea recta ($y = \hat{\mu}$) que atraviese los datos de cada clase respecto al tiempo, notamos que la gráfica para los conductores agresivos tiene una mayor cantidad de valores alejados de la recta, lo que ocasiona que la desviación estándar y los valores esperados aumenten para esta sección particular de los registros (véase figura M1.1).



fig(M1.1) Comparación de giroscopios respecto al timestamp por clase.

Se entrenó el modelo de clasificación con la desviación estándar de cada característica para ciertos intervalos de tiempo (10s, 25s y 50s), resolviendo el problema de juzgar a los conductores con un solo instante.

El objetivo de contar con las desviaciones por intervalo es obtener una métrica que mejor describa los comportamientos erráticos de cada tipo de conductor. Entonces, mientras más intervalos se definan, menos valores hay para calcular la desviación estándar de cada uno, por lo que se espera que todas las desviaciones de una sola clase no sean consistentes entre sí, volviendo más difícil para el modelo clasificar los datos.

Cada modelo se entrenó con las variables que tienen un alto coeficiente de correlación de Pearson, es importante puntualizar que la correlación de los datos usados para entrenar los modelos son diferentes en este caso, anteriormente fueron obtenidas con las variables crudas (aceleraciones y giroscopios en x, y, z y timestamp), pero en este caso, tomamos como variables la desviaciones estándar a partir de los datos originales.

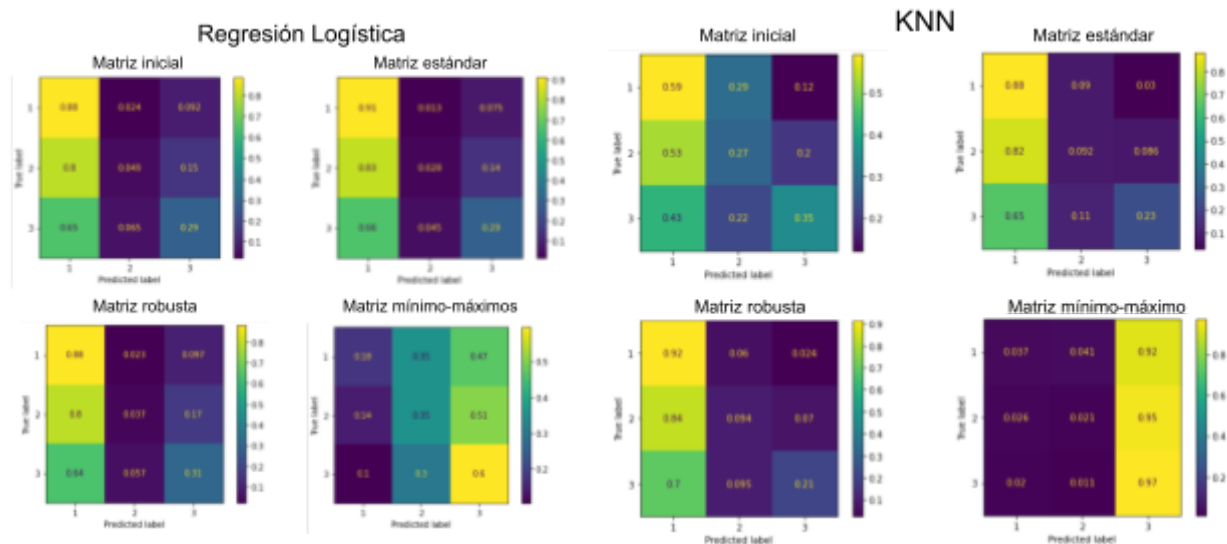
Modelos utilizados

Para cada intervalo de tiempo se usaron dos modelos de clasificación supervisados: regresión logística y perceptrón, con conjuntos de entrenamiento distintos. Los modelos de regresión logística se entrenaron para clasificar 3 grupos (lento, normal y agresivo), en cambio los de perceptrón se entrenaron para clasificar dos clases, ello requirió de otro preprocesamiento: los datos de la clase lento y normal se convirtieron en la clase 2 (y se seleccionó aleatoriamente la mitad de ellos para mantener un balance en la cantidad de datos respecto a la clase agresivo -clase 3-).

Los modelos de perceptrón se entrenaron con distintas épocas, graficando el error por cada una de ellas, seleccionando los modelos donde el número de épocas es el mínimo (para cada intervalo).

Resultados

En modelos de 3 clases




fig(R1.1) Matrices de confusión para regresión logística

fig(R1.2) Matrices de confusión para kNN

Los dos modelos utilizados fueron entrenados con distintos tipos de escalamientos (las matrices de confusión iniciales representan el resultado de modelos que no tienen datos escalados). Para el modelo de Regresión Logística fig(R1.1), la Matriz inicial y la estándar, muestran precisiones similares, con la estándar siendo un poco mejor que la original (46.2% contra 45.7%).

Por otro lado, en el modelo kNN fig(R1.1), tuvo varias diferencias en cuestión a precisiones, donde el escalamiento mínimos-máximos es el peor con 27.7%, pero mayor confiabilidad con el uso del escalamiento robusto con un valor de 46.4%, mejor que sin escalar los datos (42.4%, matriz inicial).

En modelos de 2 clases



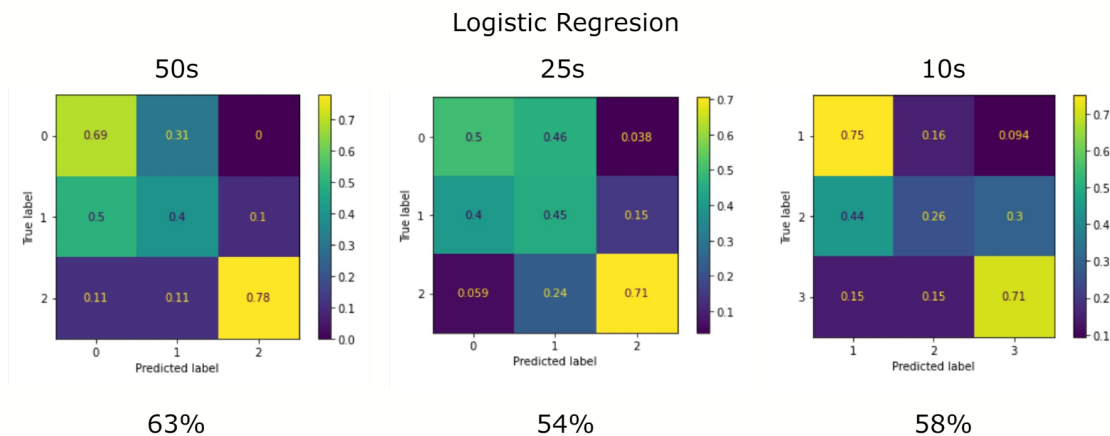
fig(R2.1) resultados de cada modelo con su matriz de confusión.

Como se puede observar en la figura R2.1, los porcentajes de precisión mejoraron en todos los modelos y de estos, kNN tiene el mayor, sin embargo, tomando en cuenta las matrices de confusión, se descarta este modelo ya que no es el que mejor cumple con el objetivo. Por otro lado, random forest, pese a que tiene un porcentaje menor en general, su precisión para clasificar agresivos sí aumenta significativamente.

En modelos de intervalos

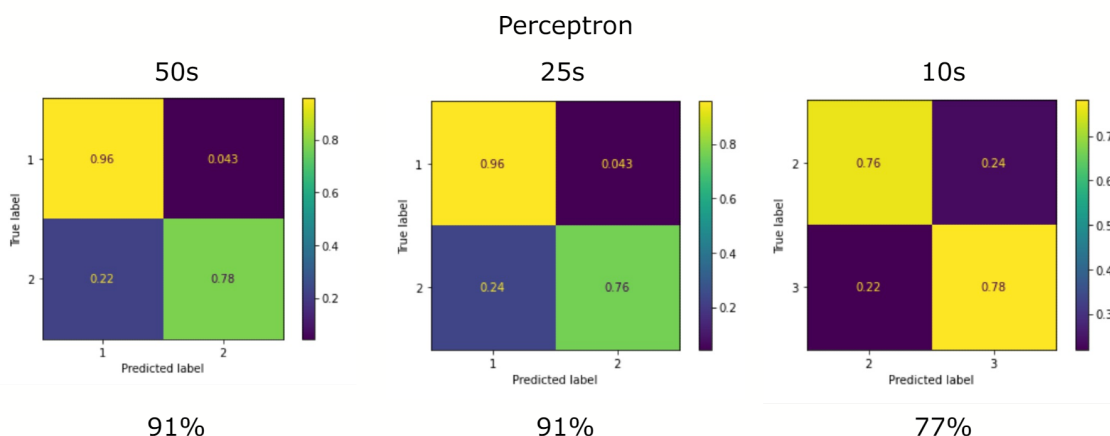
Regresión

logística



fig(R3.1) resultados del modelo de regresión logística en cada intervalo.

Perceptrón



fig(R3.2) resultados del perceptrón en cada intervalo.

Como se puede ver en las figuras R3.1 y R3.2, hay una clara diferencia entre los modelos que usaron intervalos de 50 segundos y de 10 segundos; los modelos de regresión logística y de perceptrón tienen porcentajes de precisión de 63% y 91% (en intervalos de 50 segundos) mientras que los otros modelos (con intervalos de 10 segundos) solo alcanzan 58% y 77% respectivamente.

Conclusiones

Dentro de los modelos de dos y tres clases nuestros modelos son poco confiables, luego de varias pruebas y modelos con baja confiabilidad, se deduce que la muestra es mala.

Los resultados para los modelos de tres y dos clases son deficientes dado que los datos son insuficientes y están sesgados, la muestra pertenece a un solo conductor que arbitrariamente clasificó como agresiva, normal o lenta alguna forma de conducir. Las vibraciones del auto afectaron los registros del sensor, generando ruido; nótese que los registros de cada tipo de conductor se hicieron de forma consecutiva, entonces al cambiar la forma de conducir se genera ruido extra. Además, la muestra se tomó de forma imprecisa: se supone que son dos registros por segundo, pero hay segundos con un solo registro.

Es importante mencionar que el escalamiento de los datos no tuvo efectos notables en la confiabilidad del modelo, tampoco fue necesaria la imputación de datos, y para evitar el sobreentrenamiento de modelos, se redujo el conjunto de datos de entrenamiento en los modelos de dos clases.

El modelo de intervalos fue el que resultó en el mayor porcentaje de precisión, tanto global como para clasificar conductores agresivos, pero existe la posibilidad de que se haya linearizado el problema, lo que implica que no hay ninguna certeza de que el modelo funcione para datos distintos a los de los datasets de entrenamiento y prueba. Entonces, habría que contar con muchos más registros con los cuales evaluar el modelo para descartar esta posibilidad.

Referencias

- Aggressive Driving: Research Update. (2009). En aaafoundation.org (N.o 202-638-5944). AAA Foundation for Traffic Safety. Recuperado 18 de septiembre de 2022, de https://www.google.com/url?sa=t&rct=j&q=&esrc=s&source=web&cd=&cad=rja&uact=8&ved=2ahUKewjO677a0p_6AhVnlGoFHbmZAnUQFnoECAwQAQ&url=https%3A%2F%2Fsafty.fhwa.dot.gov%2Fspeedmgt%2Fref_mats%2Ffhwasal304%2Fresources2%2F38%2520-%2520Aggressive%2520Driving%25202009%2520Research%2520Update.pdf&usg=AOvVaw2SUUQtGj7yG7OhEzdjJS1P.
- MinMax Scaling (s.f.) sklearn.preprocessing.MinMaxScaler. Scikit-Learn. Recuperado 18 de Septiembre: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html>
- Robust Scaling (s.f.) sklearn.preprocessing.RobustScaler. Scikit-Learn. Recuperado 18 de Septiembre: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.RobustScaler.html>
- Standard Scaling (s.f.) sklearn.preprocessing.StandardScaler. Scikit-Learn. Recuperado 18 de Septiembre: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>